FCM Landmark Detection

Eksamensaflevering — KEA, Maskinlæring, maj 2026 Forfatter: Andreas Søgård Gabel

1. Problemstilling

I samarbejde med Videometer A/S er der undersøgt om frø-positioner på en standardiseret optagelsesplade kan detekteres automatisk via maskinlæring. Den nuværende arbejdsgang kræver manuel annotering af hvert enkelt frøs centermasse, hvilket både er tidskrævende og skalerer dårligt ved større datamængder.

Målet med projektet har været at træne en model der kan udpege frø-positioner i et billede med tilstrækkelig præcision til at erstatte den manuelle annotering, eller som minimum fungere som pre-annotering der reducerer det manuelle arbejde markant.

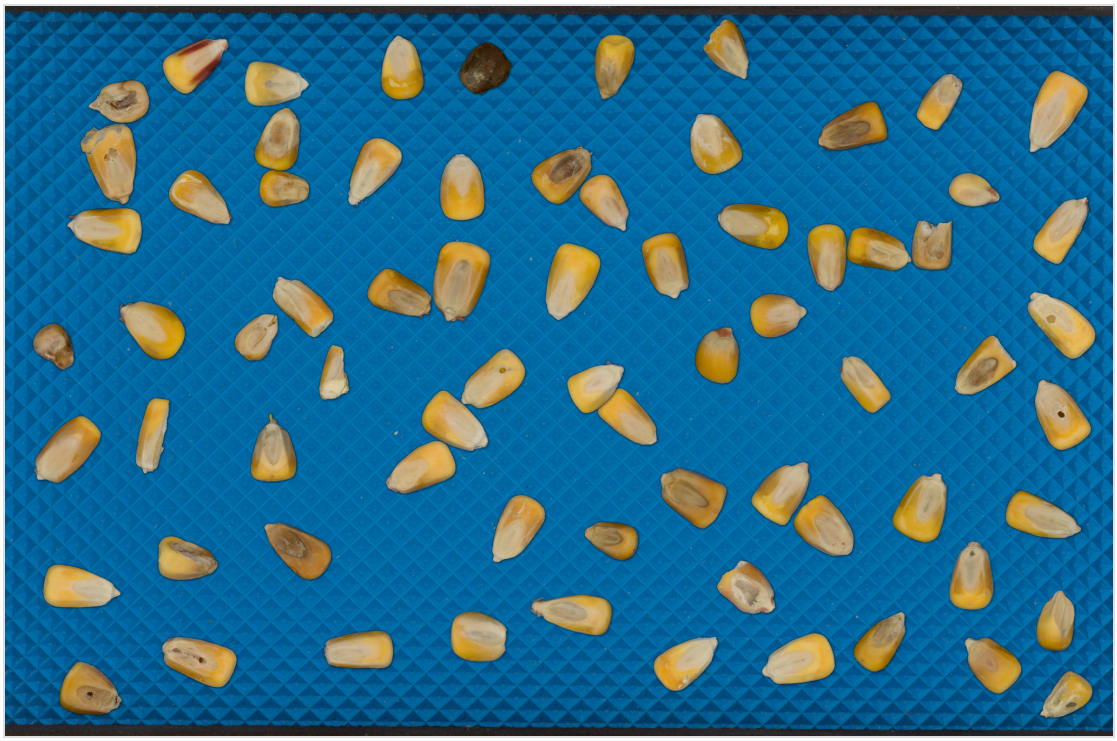
Som detektions-arkitektur er der valgt **YOLOv11n** fra Ultralytics-rammeværket. Valget skyldes en kombination af modellens lette form (~5 MB trænede vægte), gode anchor-fri performance på små objekter og kompatibilitet med Apple Silicon (MPS), som har været det primære udviklingsmiljø.

2. Datagrundlag — hvorfor syntetisk data

Adgangen til ægte Videometer-data har været begrænset gennem hele projektet: optagelserne er underlagt en NDA, mængden er lille, og manuel annotering af frø-centre er præcis det problem der ønskes løst. At basere træningen direkte på de få tilgængelige rigtige billeder ville derfor være både datafattigt og cirkulært.

I stedet er der bygget en **syntetisk data-pipeline** der procedurelt sammensætter realistiske composite-billeder: enkeltfrø-udsnit fra Videometer-optagelser placeres på et baggrundsbillede af den blå optagelses-plade, og labels genereres automatisk ud fra placeringen. Pipelinen har genereret **7.000 composite-billeder**

i 1280×1280 opløsning, og giver fuld kontrol over hvor mange frø der ligger i hvert billede, deres positioner og deres ikke-overlappende layout.



Figur 1: Et af de 7.000 syntetiske composite-billeder brugt til træning. Frø er placeret tilfældigt på en blå plade-baggrund uden overlap.

3. Tidlige tilgange og opdaget data leakage

Modellen er blevet trænet i flere iterationer hvor metodikken er strammet op undervejs:

Version	Datasæt-tilgang	Bemærkning
v1_kalibreret	Kun rene frø-udsnit, ingen baggrund	Baseline — orienteringsstudie
v2_robust	Composite med tilfældig augmentation	Test af robusthed
v3_augmented	Composite med stærkere augmentation	Validerede augmenterings-strategien
v4_composite	Større composite-datasæt, fælles baggrunde train/val	Mistænkeligt høje metrikker
v5_no_leak	**Composite med adskilte baggrunde train/val**	**Endelig model**

Ved gennemgang af v4-resultaterne er der opdaget en metodisk fejl: **de baggrundsbilleder der blev brugt til at konstruere composite-eksemplerne, var fælles mellem træningssæt og valideringssæt**. Hver baggrund optrådte under flere frø-konstellationer, men hvis den samme baggrund optrådte både i train og val, kunne modellen lære features ved baggrunden selv frem for ved frøene. Det er klassisk data leakage og forklarer hvorfor v4-metrikker var urealistisk gode.

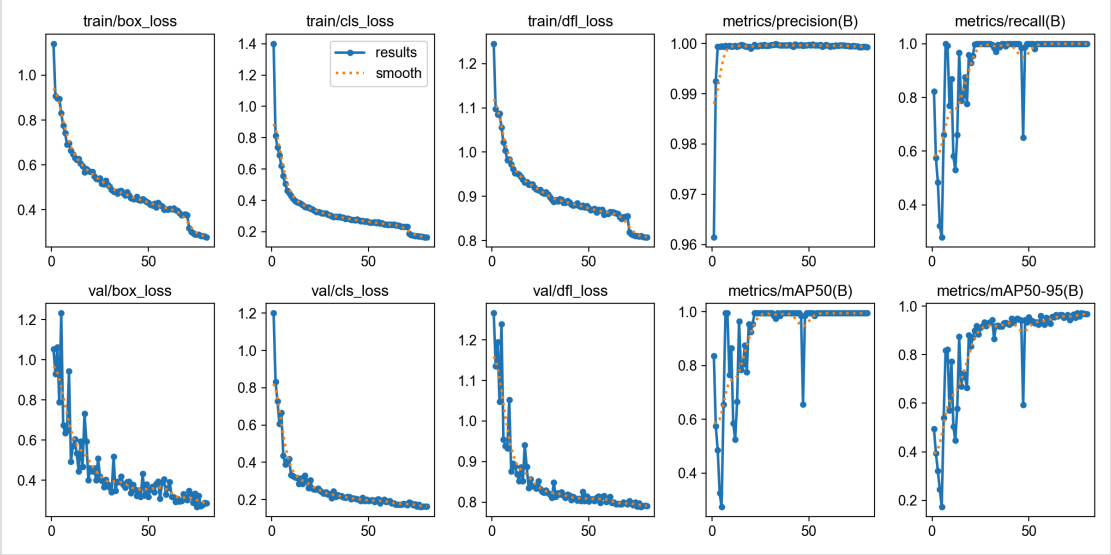
Læringen har formet hele den endelige pipeline: **enhver baggrund må kun optræde i ét split**. Den re-arkitekterede composite-generator splitter først baggrunds-poolen i train/val/test, og bygger derefter composite-billeder inden for hvert split. Det er denne disciplin der gør v5's tal troværdige.

4. Composite-pipelinen og v5_no_leak

Den endelige pipeline består af **seks moduler** der hver har ét ansvar:

1. **Baggrunds-loader** — indlæser plade-baggrunde og splitter dem i train/val/test (baggrundene blandes aldrig på tværs af splits).
2. **Frø-katalog** — holder en pulje af enkeltfrø-udsnit med metadata om størrelse og center-masse.
3. **Layout-generator** — placerer N frø tilfældigt på en baggrund uden overlap.
4. **Composite-renderer** — sammensætter baggrund + frø til ét billede og holder styr på pixel-koordinater.
5. **Label-skriver** — skriver YOLO-formatterede labels (klasse + normaliserede bbox-koordinater) per billede.
6. **Manifest-bygger** — gemmer `data.yaml` og generation-metadata så datasættet er fuldt sporbart.

Træningen af v5_no_leak er gennemført på en Mac M-chip vha. PyTorch's MPS-backend over **80 epochs** med YOLOv11n som startpunkt. Træningskonfiguration: input-størrelse 1280×1280, batch 8, learning rate auto-tuned.



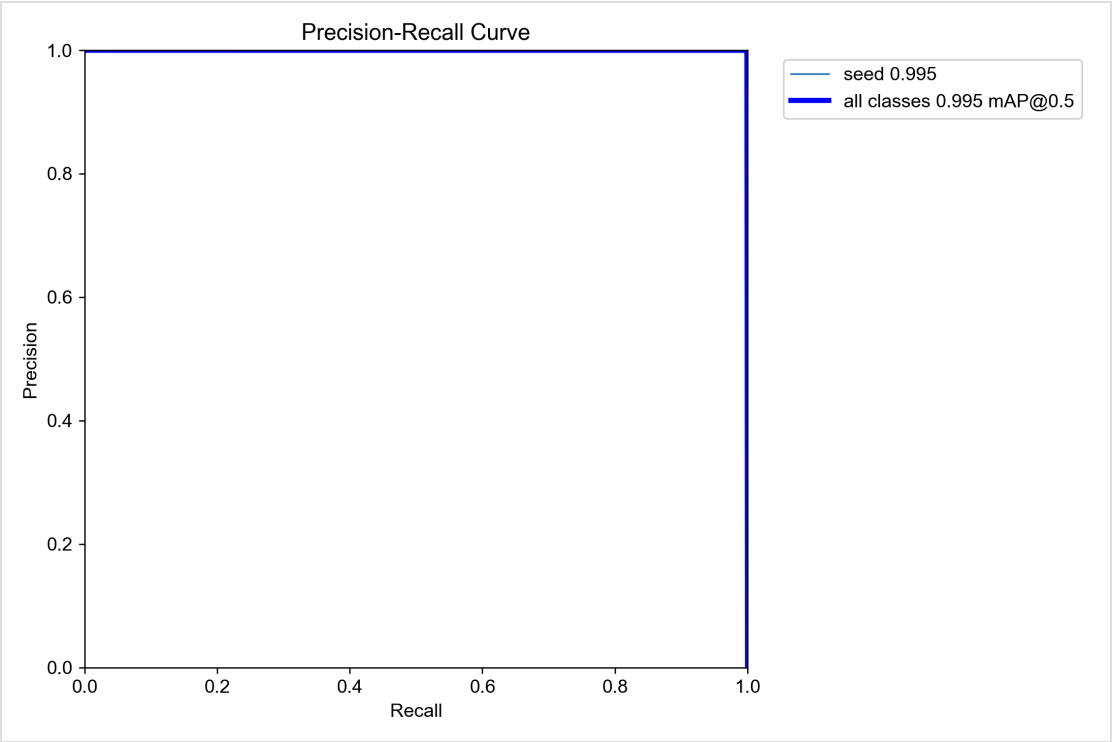
Figur 2: Train- og val-loss + metrikker over 80 epochs. mAP@50 konvergerer hurtigt, mens mAP@50-95 fortsætter med at stige langsomt.

5. Resultater

På valideringssættet — som ingen baggrunde deler med træningssættet — har v5_no_leak opnået følgende slutmetrikker:

Metric	Værdi
Precision	0.999
Recall	1.000
mAP@50	**0.999**
mAP@50-95	**0.969**

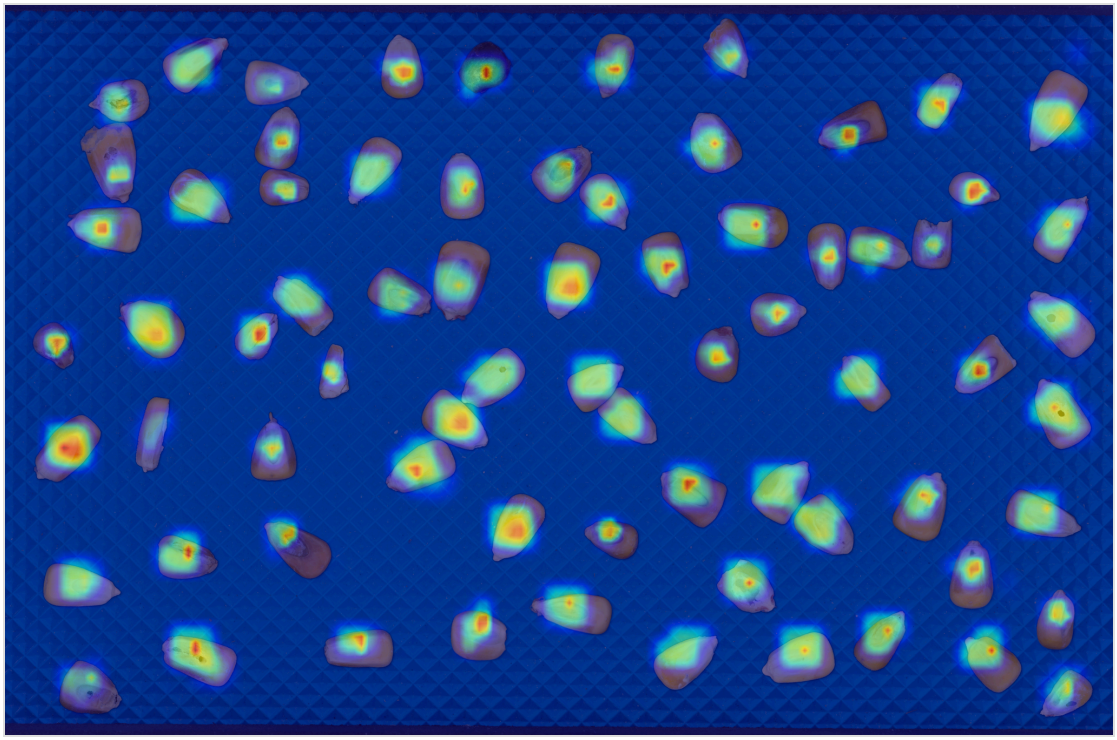
Tallene er konsistente med kvaliteten af de syntetiske data og indikerer at modellen har lært at lokalisere frø meget pålideligt på composite-billeder. Det skal understreges at evalueringen stadig foregår på syntetisk data — den endelige validering på rigtige Videometer-billeder er planlagt men ligger uden for denne aflevering.



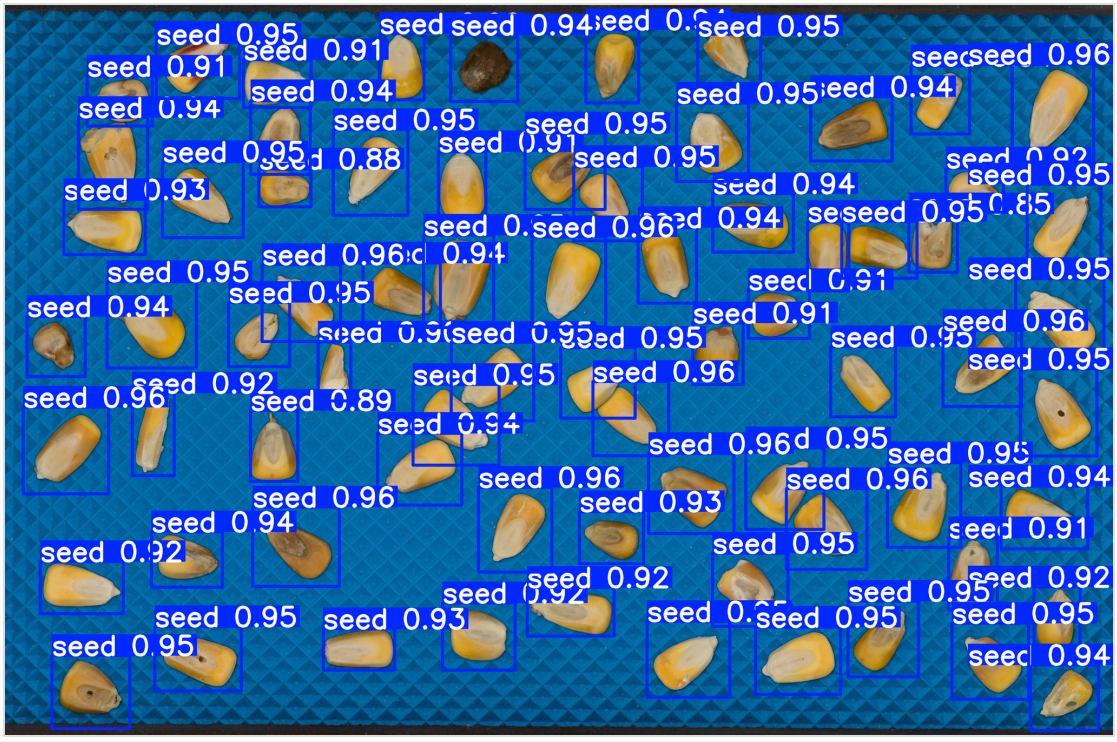
Figur 3: Precision-Recall-kurven viser at modellen holder >0.99 precision over hele recall-spektret.

Objectness heatmap som interpretability

Som interpretability-værktøj er der i Streamlit-demoen indbygget en visualisering af modellens **interne objectness-confidence** før NMS og bbox-decoding. Heatmap'et opsamles ved at hooke ind på YOLO-modellens Detect-lag og summere klassesandsynligheder per grid-celle på tværs af de tre featuremap-skalaer (P3, P4, P5).



Figur 4: Objectness heatmap (blå=lav, rød=høj) lagt oven på et testbillede. Modellens interne confidence "tænder" netop der hvor de detekterede bounding boxes ligger — visuelt bekræft af at modellen ikke "snyder" via baggrundens features.



Figur 5: Predictions fra v5_no_leak på composite_00000.png. Hver bounding box svarer til et detekteret frø.

6. Refleksion og fremtidsudsigter

Real-world validering er det vigtigste næste skridt. Resultaterne ovenfor er imponerende på syntetisk data, men gabet mellem syntetisk og rigtigt er kendt fra litteraturen. Et besøg hos Videometer er aftalt med henblik på at køre v5_no_leak på en lille mængde ægte plade-optagelser og rapportere mAP samt fejl i mm via den kalibrerede mm/pixel-faktor.

Mulige forbedringer identificeret under arbejdet:

- **Mere realistisk lyssætning** i composite-generatoren — den nuværende blå plade har konstant belysning, mens rigtige Videometer-optagelser har subtile lys-gradienter.
- **Multi-class detection** — modellen detekterer kun "frø". Hvis flere kornsorter skal skelnes, skal pipelinen udvides med klasse-balancerede syntetiske eksempler.
- **Domain adaptation** — selv en mindre fine-tuning på ægte data forventes at forbedre generaliseringen betydeligt.

Metodisk refleksion. Den vigtigste læring fra projektet er ikke selve modellens arkitektur, men opdagelsen af data leakage mellem v4 og v5. Det demonstrerer hvor let det er at producere imponerende tal på en utæt evaluering, og hvor vigtigt det er at splitte ikke kun

eksemplerne

men også

de underliggende kilder

(her: baggrunds-billederne) når et syntetisk datasæt bygges fra et lille sæt råmaterialer.

Repo: . Demo: `streamlit run scripts/03_demo/upload_demo.py` *. Reproducer rapport-billeder:* `python scripts/05_generate_report_assets.py` *.*